分类号 TP391　　密　级

U D C　　编　号 10486

武漢大學

博　士　学　位　论　文

神经网络特征学习的动力学特性研究

研　究　生　姓　名:　陈彦伯

指导教师姓名、职称:　刘威威　教授

学 科、 专 业 名 称:　计算机科学与技术

研　究　方　向:　机器学习

二〇二五年十二月九日

A Research on the Feature Learning Dynamics of Neural Networks

Candidate: CHEN Yanbo

Supervisor: Prof. LIU Weiwei

Major: Computer Science and Technology

Speciality: Machine Learning

School of Computer Science

Wuhan University

December 9, 2025

论 文 原 创 性 声 明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已发表或撰写的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

学位论文作者（签名）：

年　　月　　日

武汉大学学位论文使用授权协议书

本学位论文作者愿意遵守武汉大学关于保存、使用学位论文的管理办法及规定, 即：学校有权保存学位论文的印刷本和电子版, 并提供文献检索与阅览服务；学校可以采用影印、缩印、数字化或其它复制手段保存论文；在以教学与科研服务为目的前提下, 学校可以在校园网内公布部分及全部内容.

1、 在本论文提交当年, 同意在校园网内以及中国高等教育文献保障系统 (CALIS)、高校学位论文系统提供查询及前十六页浏览服务.

2、 在本论文提交 □ 当年/ □ 一年/ □ 两年 / □ 三年以后，同意在校园网内允许读者在线浏览并下载全文，学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务.(保密论文解密后遵守此规定)

论文作者 (签名)：_____

学　　号：_____

学　　院：_____

日期：　　年　　月　　日

论文创新点

本文从动力学视角出发对神经网络的特征学习过程进行了深入探究，建立了丰富的理论成果，为高性能深度学习模型的设计与优化提供了理论支撑。本文的主要创新点可以概括如下。

- 1
- 2

(1) 给出了神经网络特征学习的范式.

(2) 在计算机视觉（computer vision, CV）、自然语言处理（natural language processing, NLP），以及

(3) 强调了标点符号等的用法. 指出了

目　　录

摘要 **III**

ABSTRACT **V**

第一章　绪论 **1**

1.1　研究背景与意义 1

1.2　国内外研究现状 3

1.2.1　学习理论的范式演变 3

1.2.2　现代特征学习理论的研究进展 5

1.3　主要研究问题与技术路线 5

1.3.1　研究问题 6

1.3.2　技术路线 6

1.4　论文结构安排 6

第二章　特征学习理论的分析框架 **9**

2.1　特征学习理论的基本概念 9

2.2　特征与特征学学习 10

2.3　特征学习理论的分析框架 10

第三章　通用任务的特征学习理论 **11**

3.1　对抗训练与特征塌缩现象的基础概念 13

3.1.1　对抗训练 13

3.1.2　特征塌缩 13

3.2　实证研究 15

3.2.1　实验设置 15

3.2.1.0.1　Models 15

3.2.1.0.2　Adversarial Training Methods. 15

3.2.1.0.3 Implementation Details. 15
3.2.2 Neural Collapse in Adversarial Training 16
3.2.3 Simplex Compression Phenomenon 17
3.2.4 Ablation Experiment 17

第四章 图像任务的特征学习理论 21

第五章 文本任务的特征学习理论 23

第六章 总结与展望 25

参考文献 25

攻博期间发表的科研成果目录 29

致谢 31

摘　　要

。

关键词: 毕业论文, LaTeX, 模板

ABSTRACT

This thesis is a study on the theory of ....

Key words: LaTeX, ...

第一章　绪论

近十年来，基于神经网络（neural network）的深度学习（deep learning）技术凭借其卓越的任务性能与广泛的应用场景，已逐渐成为人工智能领域的支柱性技术，在计算机视觉、自然语言处理、智能推荐等领域实现了突破性进展。然而，神经网络的“黑盒”特性始终制约着该技术的进一步发展与可信应用。深度学习模型内部的特征（feature）提取与作用机制缺乏合理的可解释性，导致其在安全攸关场景中的部署面临挑战，同时也使得深度学习的发展长期依赖经验驱动，缺乏先验的理论指导。

传统学习理论（learning theory）囿于统计学、最优化理论等基础理论的分析框架，难以适配深度学习模型的高维性、非线性与动态演化特性，与深度学习的实际应用之间存在显著差异。为弥补这一差异，一系列现代机器学习理论应运而生；本文所关注的特征学习理论[a]（*Feature Learning Theory*，*FLT*）[1–4] 便是其中的倍受关注的研究方向之一。该理论致力于揭示神经网络从数据中提取并利用特征的内在规律，为深度学习的可解释性与可信性提供理论依据。

本章将首先阐述 FLT 的研究背景与意义，然后系统梳理国内外研究现状，并明确本研究的主要目标与贡献，最后介绍论文的整体结构安排。

§1.1　研究背景与意义

FLT 作为深度学习领域的新兴基础理论，聚焦于揭示神经网络在学习算法的驱动下从训练数据中自动提取并利用有效特征的内在规律，其研究不仅具有深刻的学术理论价值，更对人工智能高效、安全的落地实践具有关键的指导意义。

相较于支持向量机、逻辑回归等传统机器学习模型，以卷积神经网络（Convolutional Neural Network, CNN）、自编码器（Autoencoder, AE）、Transformer（TF）等为代表的神经网络深度学习模型，具备从图像、语音、视频等高维复杂模态数据中自动提取有效特征的核心能力，从而在图像分类、自然语言处理等复杂任务中实现了性能的跨越式提升。然而，人们对诸如“神经网络如何自动从训练数据中提取有效特征”、“网

[a]在本文中，FLT 特指一类新兴的深度学习理论分支，而非广义上所有与特征相关研究的统称。为避免概念歧义，我们将在 §1.2.1中明确给出 FLT 的核心界定，并系统对比 FLT 与其他相关理论体系的异同。

络提取的特征如何随训练过程演化”、“为何特定结构的网络只能在一部分学习任务中表现出色”等核心问题缺乏系统性认知，这导致深度学习模型常被视为不可解释的黑盒子，严重阻碍了其理论发展与可信应用。特征学习理论通过数学建模、理论推导与实证分析，清晰刻画了模型结构、参数初始化与梯度下降对特征学习过程的影响，揭示了诸多深度学习模型特有属性的内在机理（如良性过拟合 [1]、特征纯化（Feature Purification）[2]、神经坍缩（Neural Collapse）[3] 等），填补了传统理论与深度实践之间的鸿沟，为深度学习的可解释性提供了有力支撑。

此外，特征学习理论还为不同领域的机器学习问题提供了统一的理论分析框架。在传统学习理论中，不同领域、场景下问题的分析框架一般也各自独立，所得结论无法相互参考比对。特征学习理论的研究，能够提炼不同领域场景、不同数据与模型假设下特征提取、优化、迭代的共性规律，构建统一的理论分析框架，打破各研究方向的壁垒。例如，特征学习理论可以在统一理论框架下分析并揭示知识蒸馏 [4]、自监督对比学习 [5] 与图神经网络学习 [6] 等多个不同场景下的前沿问题的底层原理，实现理论认知在计算机视觉、自然语言处理、智能推荐等不同领域的跨场景迁移，推动机器学习理论体系的进一步系统化与完善化。

在实践中，特征学习理论可以指导深度学习模型的设计与优化，提升模型应用的鲁棒性与泛化能力，解决实际场景中的核心技术痛点。传统深度学习模型设计多依赖研究者的经验与大量试错，具有封闭性与随机性的特点。特征学习理论的研究成果，能够为模型结构设计、训练策略选择提供明确的理论指导。例如，基于“SGD 先挖掘后优化特征”的规律 [7]，可针对性优化模型训练的学习率调度策略；基于“特征纯化提升鲁棒性 [2]”的机理，可改进对抗训练算法以增强模型的抗干扰能力；基于“混合增强（Mixup）对特征学习的增益机制 [8]”，可设计更高效的数据增强方案。这些理论指导能够大幅减少模型研发的盲目性，降低试错成本，适用于包括计算机视觉、自然语言处理在内的大多核心任务。在深度模型的实际应用场景中，数据往往存在分布偏移、噪声干扰、样本稀缺等问题，对深度学习模型的泛化能力与鲁棒性提出了较高的需求。特征学习理论针对分布外泛化 [9]（Out-of-Distribution Generalization）、异常检验 [11]、Zero-Shot 学习 [10] 等场景的研究，能够帮助模型开发者从根本上理解的特征学习过程，进而提升模型的鲁棒性与泛化能力。在上述示例中，特征学习理论通过挖掘特征与真实任务标签的内在关联，抑制虚假特征的干扰；通过学习可迁移的通用特征，提升模型在未知数据分布下的泛化性能；通过特征多样化学习，缓解小样本场景下的过拟合问题。上述分析推动了 AI 模型在医疗影像诊断、工业质检、智能驾驶、金融风控等安全攸关领域的规模化落地，解决实际场景中的核心技术痛点。

§1.2 国内外研究现状

特征，有时也被称作表示、表征（representation），广义上泛指数据在特定任务空间内的低维刻画，是一个跨越传统机器学习、深度学习与大模型时代的关键概念。与之对应，广义层面的特征学习理论，其范畴涵盖所有聚焦于特征学习过程的相关研究，其研究范式与核心关注问题，亦随技术与时代的演进发生了显著转变。本节将从横向（对比 FLT 与不同研究范式）与纵向（追踪 FLT 近些年的发展）两个维度，系统梳理国内外关于特征学习理论的研究现状。由于相关研究发展较快，成果极其丰富，本文仅选择部分代表性成果进行讨论。

§1.2.1 学习理论的范式演变

早期特征学习理论多基于统计学习理论（statistical learning theory）框架。该框架数理基础坚实、分析过程严谨，衍生出诸多形式优美的理论成果。Bengio 等 [13] 的综述文章系统总结了包括概率 PCA（Probabilistic Principal Component Analysis，PPCA）、受限玻尔兹曼机（Restricted Boltzmann Machine，RBM）、自编码器（Auto Encoders，AE）等模型的特征学习原理。然而，早期特征学习理论始终受限于统计学习理论范式，研究重心集中于经验风险最小化（Empirical Risk Minimization, ERM）与归纳偏置（Inductive Bias）约束两大宏观优化目标，而对数据与模型间的匹配关系、神经元的微观动力学行为缺乏足够关注。因此，早期特征学习理论无法分析神经网络的精细结构与特性，难以解释实践中所呈现的一系列神经网络特有现象。

随着深度学习技术的蓬勃发展，许多新型学习理论框架相继涌现，一些传统的理论框架也取得了若干新成果。例如，神经正切核（Neural Tangent Kernel, NTK）通过网络输出对参数梯度的内积定义核函数，在无限宽极限下将神经网络训练动态线性化为核回归问题，为超宽网络的收敛性与泛化性分析提供解析工具；平均场理论（mean field theory）以群体平均行为近似大规模系统中个体的复杂交互，将高维动力学降维为可解的自洽方程，适用于刻画神经网络特征学习动态或多智能体交互机制；梯度流（gradient flow）作为梯度下降的连续时间极限，通过常微分方程描述参数演化轨迹，是分析非凸损失曲面几何性质与优化收敛行为的核心框架；而作为传统学习理论的代表，概率近似正确（Probably Approximately Correct，PAC）理论也被应用到了神经网络上。该理论通过样本复杂度与置信度量化模型泛化能力，为算法的近似正确性提供概率保证，在深度学习时代也取得了若干新的研究成果。我们在图1.1中梳理了当前机器学习领域若干主流的学习理论框架，并附列了各框架对应的代表性研究成果。

2021 年前后，Allen-Zhu 与 Li [2,4] 提出了现代特征学习理论研究范式，并引发了

学界的广泛关注与讨论。为避免歧义，本文将使用“现代特征学习”来特指这类新型研究范式，而用“早期特征学习”或“传统特征学习”来指代早期基于统计学习理论的研究。特别地，英文缩写“FLT”仅用于指代现代特征学习理论。鉴于 FLT 仍处于新兴发展阶段，学术界对其核心定义尚未形成统一共识。为保证研究的严谨性，我们特对 FLT 作出如下界定。

> 本文所讨论的特征学习理论是一类有限、离散，且算法相关的理论分析框架。该理论能够分析具体学习任务（由数据建模、模型结构、学习算法等要素共同决定）中模型参数从随机初始化到趋近于收敛的整个迭代过程。

我们对 FLT 的三大核心特性解释如下：

- **有限性**：以有限宽度网络为研究对象，并不要求网络宽度趋向无穷。相比 NTK 等无限维理论分析框架，FLT 可以得到关于网络宽度的非渐进（non-asymptomatic）的结论，帮助研究者更深入地理解网络参数如何定量地影响网络的表现。
- **离散性**：聚焦于模型参数的离散迭代优化过程，而非将其近似为连续的优化流。因此，FLT 不同与梯度流、均值场理论等连续化分析框架，往往不许需要对优化目标做过于理想化的假设。
- **算法相关性**：考虑具体学习算法对特征学习过程的影响，这与 PAC 学习、VC 维理论、表示性理论等传统学习理论的核心假设存在本质区别。

图1.1展示了 FLT 与同时期其他常见学习理论分析框架的关系。

均值场理论（MF）: [2]
梯度流（GF）: [2]
神经正切核（NTK）: [2]
概率近似正确（PAC）: [2]
可表示性理论（EA）: [2]
VC 维理论（VCD）: [2]
样本复杂度（SC）: [2]

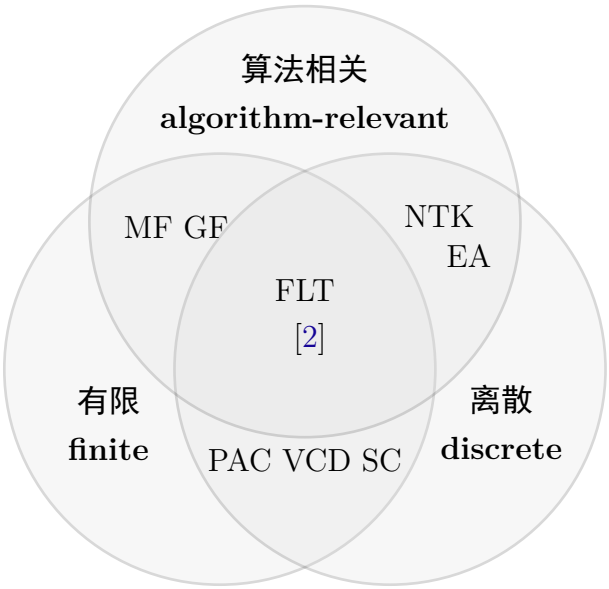

图 1.1: 学习理论分类图。

总而言之，FLT 关注特定学习任务中神经元从初始化到收敛的整个迭代过程，因

此能在保证模型泛化性性能的前提下分析收敛后所得神经网络的更多精细特性，从而更加适应深度学习时代对基础理论的需求。

§1.2.2 现代特征学习理论的研究进展

FLT 是一套面向实践应用的理论体系；凡是在实际训练、推理过程中神经网络表现出的性质、现象，都可作为 FLT 的分析对象与研究载体。在 FLT 发展初期，研究者主要关注通用学习任务中神经网络的共有性质，例如良性过拟合的发生机制 [1]、随机梯度下降（Stochastic Gradient Descent, SGD）算法的优化动力学机理 [7]，以及对比学习范式下特征表征的学习机制与优化策略 [5] 等。在本文中，我们针对对抗训练场景下的特征单纯形压缩现象（complex compression phenomenon）展开了系统性分析。我们证明单纯形压缩是神经塌缩（Neural Collapse, NC）现象在对抗训练下的自然推广与延伸。

随着与 FLT 相关探索的不断深入，关于通用任务下神经网络的共性性质研究已日趋完善。在此背景下，研究者的关注焦点开始转向更为细分、具体的实践场景与技术环节，例如知识蒸馏的特征迁移机制优化 [4]、Mixup 数据增强策略下的特征分布演化规律 [8] 等——这类研究均旨在从细粒度层面挖掘特征学习的内在机理，为特定技术方案的优化提供理论支撑。本文第三章聚焦重构式异常检测（Reconstruction-Based Anomaly Detection, RBAD）场景下的特征学习动力学过程展开系统分析，最终证实：仅在正常数据上完成训练的生成式网络，在对异常样本进行重构时会产生显著更大的误差，基于这一特性可实现对异常点的有效检测。

再然后，随着大语言模型（Large Language Model）时代到来，一些关于语言模型（比如 TF）与扩散模型的分析也出现了。本文基于神经网络研究了 QA 问题中的知识提取。

§1.3 主要研究问题与技术路线

本研究计划围绕特征学习理论的核心科学问题（见 §1.3.1），总结现有理论与与相关参考文献，建立统一的分析框架。随后，我们聚焦对抗训练（Adversarial Training）、重构式异常检测（Reconstruction-Based Anomaly Detection，RBAD）、与 LLM 问答（Question Answering，QA）为例，深入考察神经网络在通用、图像和文本任务常见下的特征学习、演化机制，并总结归纳特征学习的共性特点与不同模型的适配机制。

§1.3.1 研究问题

本文主要关注下述三个特征学习领域的核心问题。

- 特征提取机制：神经网络如何自动从训练数据中提取有效特征？
- 特征演化机制：网络提取的特征如何随训练过程演化？
- 网络适配机制：为何特定结构的网络只能在一部分学习任务中表现出色？

本文将围绕上述三个问题展开研究，并在第六章对每个问题给出简短的回答。

§1.3.2 技术路线

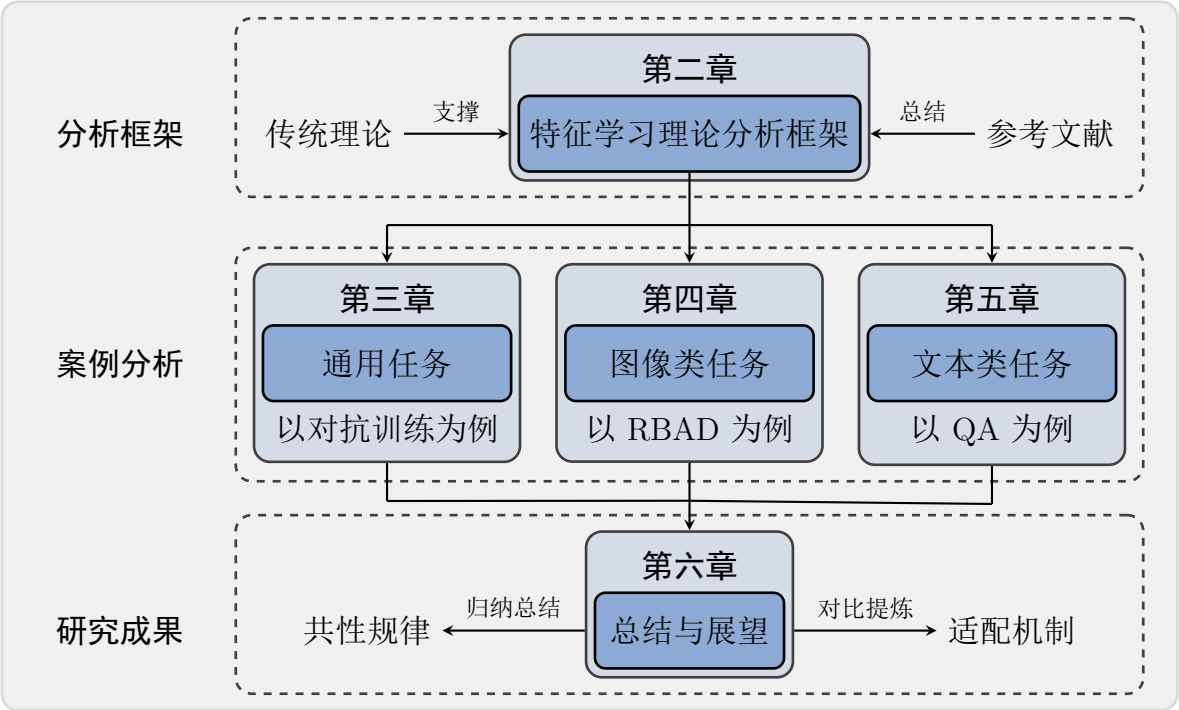

§1.4 论文结构安排

本文共有六章，其中第一章为绪论，介绍了特征学习理论的研究背景与意义，总结了该领域国内外发展近况，并概括了本文的研究内容与主要贡献。在第二章中，我们结合传统学习理论与 FLT 相关参考文献，总结了 FLT 的研究范式，介绍了该领域的基础理论知识。在第三到第五章，我们分别从通用任务、图像任务与文本任务的角度探索模型的特征学习特性。其中：

- 第三章以对抗训练为研究场景，分析全连接神经网络特征学习动力学基础与神经塌缩特性，探究单纯形压缩现象的表征、成因及其与神经塌缩的关联差异，验证其对模型鲁棒性的影响。
- 第四章聚焦 RBAD 场景，探究图像数据与 RBAD 的适配性，构建卷积神经网络特征学习动力学模型，推导特征提取与数据重建的关联机制并开展实验验证。
- 第五章针对问答任务，构建 Transformers 知识提取动力学模型，解析自注意力机制驱动的知识捕捉与表达逻辑并验证其有效性。第六章对全文研究成果进行总结，分析研究局限性，并展望未来研究方向。

本文第三到五章的分析始终围绕着我们在 §1.3.1中提到的三个研究问题，即“网络如何自动提取有效特征”、“特征如何随训练过程演化”与“为何特定结构的网络在特定类型的数据上具有更优特征学习能力”。在第六章，我们总结了全文的核心工作，为上述研究问题提供了一份详细的分析、回答。并就未来的潜在研究方向进行了深入思考。

第二章　特征学习理论的分析框架

FLT 作为深度学习领域新兴的基础理论分支，既承袭了传统统计学习理论的系统性理论框架，又深受深度学习应用中实际问题的驱动。本章将从基础定义出发，系统阐述特征学习理论的核心概念与关注焦点。我们首先基于机器学习理论的视角，解构一般学习任务并剖析其“四要素”，随后顺势引出“特征”与“特征学习”这两个核心概念，并辅以必要的概率统计工具。最后，我们将归纳总结特征学习理论的分析框架。

§2.1　特征学习理论的基本概念

在本文中，我们分别用小写与大写粗体字母来表示（列）向量和矩阵。给定 $d \in \mathbb{N}^+$ 和 $\boldsymbol{v} \in \mathbb{R}^d$，记 $\boldsymbol{v}$ 的第 i 个元素（$1 \le i \le d$）为 $\boldsymbol{v}^{(i)}$，即 $\boldsymbol{v} = (\boldsymbol{v}^{(1)}, \boldsymbol{v}^{(2)}, \cdots, \boldsymbol{v}^{(d)})^\top$。类似地，我们用 $\boldsymbol{M}^{(i)}$ 来表示矩阵 $\boldsymbol{M}$ 的第 i 列，并记 $\boldsymbol{M} = (\boldsymbol{M}^{(1)}, \boldsymbol{M}^{(2)}, \cdots, \boldsymbol{M}^{(d)})$。给定 $N \in \mathbb{N}^+$，我们记指标集 $\{1, 2, \cdots, N\}$ 为 $[N]$。对任意 $n \in [N]$，为简单起见，我们令 $[N \backslash n] := \{1, \cdots, n-1, n+1, \cdots, N\}$。

给定模型族 $\mathcal{F}$，机器学习的核心任务是训练一个模型 $f \in \mathcal{F}$，使其能够对输入数据 $\boldsymbol{z}$ 做出精准的预测。其中，根据不同的学习任务，$\boldsymbol{z}$ 可以取不同的形式，例如图像、文本、基因序列等，而模型的功能则可以是分类、回归、生成或聚类等。对于任意输入值 $\boldsymbol{z}$，我们可以通过定义一个损失函数（loss function）$\ell(f, \boldsymbol{z})$ 来量化模型预测值 $f(\boldsymbol{z})$ 的准确程度。给定数据集 $\mathcal{D}$，模型 f 在 $\mathcal{D}$ 上的经验风险（empirical risk）定义为：

$$\hat{R}(f; \mathcal{D}) = \frac{1}{|\mathcal{D}|} \sum_{\boldsymbol{z} \in \mathcal{D}} \ell(f, \boldsymbol{z}). \tag{2.1}$$

经验风险是模型 f 在训练数据集 $\mathcal{D}$ 上的平均损失，可用于评估模型 f 在训练数据集 $\mathcal{D}$ 上的性能，并作为优化目标来训练模型。具体来说，我们希望找到一个模型 f^*，使得经验风险最小化，也即：

$$f^* = \arg\min_{f \in \mathcal{F}} \hat{R}(f; \mathcal{D}). \tag{2.2}$$

在实际场景中，我们需要借助优化算法来求解上述优化问题。常见的优化算法包括梯度下降（Gradient Descent，GD）、随机梯度下降（Stochastic Gradient Descent，SGD）、

Adam 等。在相关文献中，数据集、模型族、损失函数与优化算法共同定义了一个具体的学习任务，构成了该任务的四大核心要素。

具体来说，我们希望模型 f 能够满足以下条件：

$$f(\boldsymbol{x}) = y \tag{2.3}$$

其中 y 是 $\boldsymbol{x}$ 的标签。在统计学习理论中，我们通常将模型 f 表示为函数空间 $\mathcal{F}$ 中的一个元素，即 $f \in \mathcal{F}$。我们称 $\mathcal{F}$ 为假设类（hypothesis class）。我们称 $\mathcal{F}$ 为假设类（hypothesis class）。

学习任务（learning task）一般由数据集、假设类（hypothesis class）、优化算法与评价指标决定。这四个东西一般也被成为机器学习的四大核心要素。具体来说，给定数据集 $\mathcal{D}$ 与假设类 $\mathcal{H}$，我们需要设计一个风险函数 $\mathcal{R} : \mathcal{H} \times \mathcal{D} \to \mathbb{R}$ 来评价模型在学习任务上的性能，并基于该风险函数设计优化算法 $\mathcal{A}$，最终通过评价指标 $\mathcal{E}$ 来评估模型的性能。数据层面，FLT 一般采取信号-噪音模型（Signal-to-Noise Model，SNM）来刻画数据分布。以图像为例，。因此，

性质 2.1.1 (**高维正交性**)
性质2.1.1说明了正交假设的合理性，因为高位空间中的总是趋近于正交的。

§2.2 特征与特征学学习

§2.3 特征学习理论的分析框架

第三章　通用任务的特征学习理论

本章将围绕神经网络的特征塌缩（Neural Collapse，NC）现象展开，并探索其背后的特征学习机制。特征塌缩由 Papyan 等 [?] 首次发现并总结，是一种普遍存在于神经网络输出层的几何特征。具体而言，Papyan 等 [?] 研究了分类任务中训练的最终阶段（Terminal Phase of Training，TPT），发现输出层特征在该阶段会坍缩为一个等角紧框架（Equiangular Tight Frame，ETF）结构。

NC 已被证实是跨数据集和网络架构的普遍现象。许多先前的研究将这一几何结构特征应用于离分布检测（10）、长尾学习（11）和对抗训练（12）等任务。本文重点探讨 AT 下的神经网络特征。此处 AT 指通过特定训练范式增强神经网络对抗鲁棒性的方法（13），具体定义可参阅第 1.1 节。已有研究（12）发现，神经网络特征在对抗训练中普遍存在。然而，通过 AT 训练的神经网络与传统训练模型存在显著差异（14,15）。由此引出两个核心问题：标准神经网络特征与对抗性神经网络特征的本质区别是什么？这种差异背后的本质特征及其理论依据又是什么？本文的核心目标在于系统阐释标准神经压缩（NC）与对抗神经压缩（AT）的差异。具体而言，我们通过实证研究揭示了对抗训练（AT）对神经压缩几何结构的影响，并发现了单纯形压缩现象。研究发现，在 AT 的最终阶段，压缩后的单纯形 ETF 几何尺寸较标准神经压缩显著缩小，且随着对抗样本扰动半径的增大，压缩程度呈现递增趋势。图 1 直观展示了这一研究发现。我们首先通过实证研究证明，单纯形压缩现象在各类模型和数据集中普遍存在且具有普适性。在此基础上，我们从理论层面阐释了自适应训练（AT）引发该现象的作用机制。研究还表明，随着扰动半径的增大，压缩程度会显著增强。特别值得注意的是，我们的理论预测与第 3.3 节展示的实验结果高度吻合，这为我们的实证发现提供了有力佐证。本文其余部分结构如下：第 1 节和第 2 节分别介绍相关研究及术语。我们在此呈现实证研究结果。

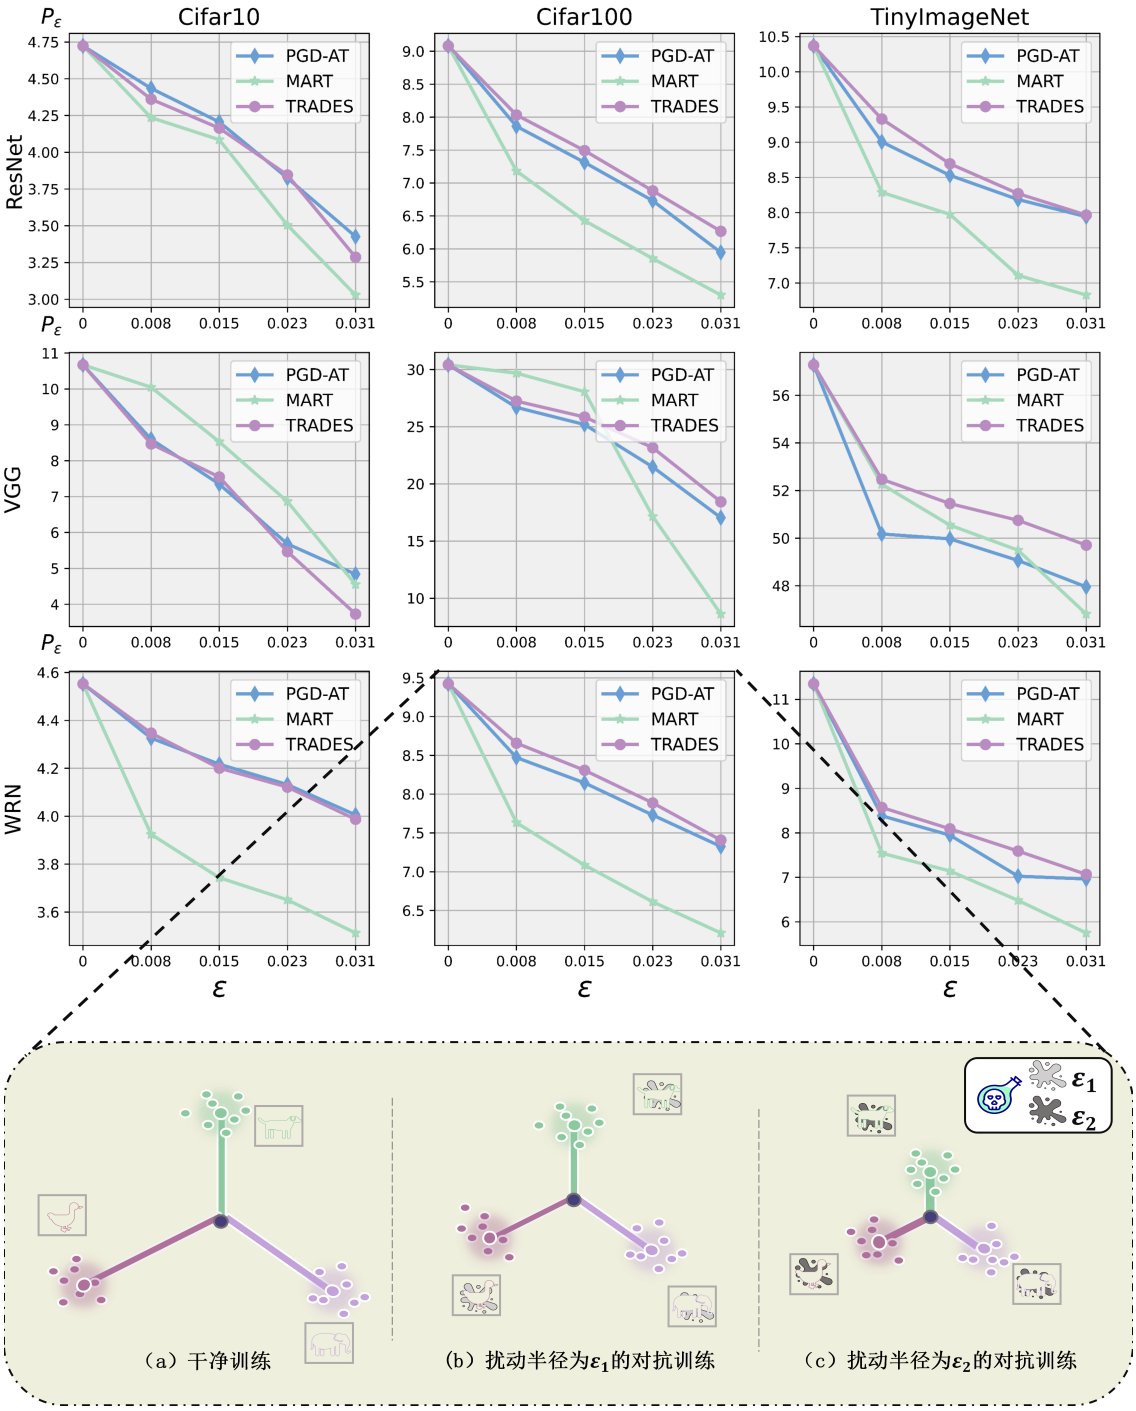

图 3.1: 线型图（上）展示了关于单纯形压缩现象的主要实证结果。我们绘制了三种对抗训练方法（包括 *PGD-AT*、*TRADES* 和 *MART*）在不同扰动半径 $\epsilon \in \{0\ 2/255\ 4/255\ 6/255\ 8/255\}$ 下的单纯形范数 P_c（参见等式??）观测值。。此处 $\epsilon = 0$ 表示干净训练。单纯形范数是使用训练数据计算的。底部：三分类任务中单纯形压缩现象的可视化。我们观察到几何尺寸（即单纯形 *ETF* 结构在 *AT* 下的单纯形范数 P_c）的减小；且随着扰动半径的增加，单纯形范数减小（此处 A、B 和 C 分别代表扰动半径的增加）。我们称这种塌缩 *ETF* 压缩的现象为单纯形压缩现象。

§3.1 对抗训练与特征塌缩现象的基础概念

§3.1.1 对抗训练

我们首先引入对抗样本（adversarial example）的概念。在图像分类问题中，对抗样本 $\boldsymbol{x}^{adv}$ 是一类经过恶意构造的样本，其在视觉上与干净样本 $\boldsymbol{x}$ 高度相似，但会迫使分类器对 $\boldsymbol{x}^{adv}$ 和 $\boldsymbol{x}$ 做出不同的预测。更具体地说，给定分类器 f，对于任意 $\boldsymbol{x} \in \mathbb{R}^d$，我们称 $\boldsymbol{x}^{adv}$ 为 f 在 $\boldsymbol{x}$ 处的ϵ-对抗样本，如果 $\boldsymbol{x}^{adv}$ 满足 $f(\boldsymbol{x}) \neq f(\boldsymbol{x}^{adv})$ 且 $\|\boldsymbol{x}^{adv} - \boldsymbol{x}\|_p \leq \epsilon$。在此定义中，常数 ϵ 量化了 $\boldsymbol{x}$ 与 $\boldsymbol{x}^{adv}$ 之间允许的最大扰动，以确保两者的视觉相似性，在文献中通常被称为 *扰动半径* (*perturbation radius*)。对抗训练（AT）最初由 Madry 等 [16] 提出，是一种旨在提升机器学习模型对对抗样本鲁棒性的训练范式。AT 的核心思想是利用构造出的对抗样本来训练分类器。已有研究 [?], wat,mart,fat,eat,robnc 证明，经过对抗训练的分类器能够“净化”对抗样本的扰动，从而比正常训练的分类器具备更强的鲁棒性。

§3.1.2 特征塌缩

在 §2.2 中，我们引入了特征提取器的概念：一个神经网络分类器通常由一个特征提取器（feature extractor）和一个线性分类器（linear classifier）组合而成。在本文中，我们用 $\boldsymbol{h} : \mathbb{R}^d \to \mathbb{R}^{d'}$ 来表示特征提取器。对于任意输入 $\boldsymbol{x} \in \mathbb{R}^d$，$\boldsymbol{h}(\boldsymbol{x})$ 在文献中通常被称为最后一层特征（last layer feature），也即 §2.2 中所提到的高级特征。这里，d' 表示最后一层特征的维度。NC 主要涵盖了以下四个特征：

定义 3.1.1 (**特征塌缩**) 给定特征提取器 $\boldsymbol{h} : \mathbb{R}^d \to \mathbb{R}^{d'}$，我们称 $\boldsymbol{h}$ 发生了特征塌缩现象，如果 $\boldsymbol{h}$ 满足以下四个性质（记为 **(NC1)** - **(NC4)**）：

- **(NC1) 方差塌缩**：通过计算单个类别 k 中所有特征的平均值，我们可以得到第 k 类类均值向量（k-th class mean vector）

$$\bar{\boldsymbol{h}}_k := \frac{1}{N} \sum_{n \in [N]} \boldsymbol{h}(\boldsymbol{x}_{k,n}). \tag{3.1}$$

  方差塌缩指的是在 TPT 阶段，最后一层特征的类内方差趋于 0，即：

$$\left\|\bar{\boldsymbol{h}}_k - \boldsymbol{h}(\boldsymbol{x}_{k,n})\right\|_2 \to 0, \quad \forall k \in [K], n \in [N]. \tag{3.2}$$

- **(NC2) 收敛到广义单纯形等角紧框架**：在 TPT 阶段，最后一层特征的类均值向量收敛到定义3.1.2给出的广义单纯形 ETF。为了便于实证验证，Papyan 等 [?] 进一步引入了以下数值特征来刻画 **(NC2)**：

$$\begin{aligned}&\left|\left\|\bar{\boldsymbol{h}}_k-\bar{\boldsymbol{h}}_G\right\|_2-\left\|\bar{\boldsymbol{h}}_{k'}-\bar{\boldsymbol{h}}_G\right\|_2\right|\to 0,\quad \forall k\neq k',\\&\cos\left(\bar{\boldsymbol{h}}_k-\bar{\boldsymbol{h}}_G,\bar{\boldsymbol{h}}_{k'}-\bar{\boldsymbol{h}}_G\right)\to -\frac{1}{K-1},\quad \forall k\neq k',\end{aligned}\tag{3.3}$$

其中 $\bar{\boldsymbol{h}}_G:=\frac{1}{K}\sum_{k=1}^{K}\bar{\boldsymbol{h}}_k$ 被成为中心化类均值向量（centralized class mean vector）。公式 3.3 表明中心化类均值向量将收敛到一个单纯形 ETF。

- **(NC3) 收敛到自对偶性**：在 TPT 阶段，类均值向量和线性分类器收敛到彼此的重新缩放版本，即：

$$\left\|\frac{\boldsymbol{W}^\top}{\|\boldsymbol{W}\|_F}-\frac{\dot{\boldsymbol{M}}}{\|\dot{\boldsymbol{M}}\|_F}\right\|_F\to 0,\tag{3.4}$$

其中 $\dot{\boldsymbol{M}}=\left(\bar{\boldsymbol{h}}_1-\bar{\boldsymbol{h}}_G,\bar{\boldsymbol{h}}_2-\bar{\boldsymbol{h}}_G,\cdots,\bar{\boldsymbol{h}}_K-\bar{\boldsymbol{h}}_G\right)\in\mathbb{R}^{d'\times k}$ 被成为中心化类均值矩阵（centralized class mean matrix）。

- **(NC4) 简化到最近类中心**：在 TPT 阶段，分类器收敛到选择与训练类均值最近（在标准欧氏距离下）的类别，即：

$$\arg\max_{k'}\langle\boldsymbol{w}_{k'},\boldsymbol{h}\rangle+b_{k'}\to\arg\min_{k'}\left\|\boldsymbol{h}-\bar{\boldsymbol{h}}_{k'}\right\|_2.\tag{3.5}$$

其中 $\tilde{\boldsymbol{\mu}}_c=\left(\boldsymbol{\mu}_c-\boldsymbol{\mu}_G\right)/\left\|\boldsymbol{\mu}_c-\boldsymbol{\mu}_G\right\|_2$ 被成为重新缩放的类均值（renormalized class mean）。 ▲

特征压缩现象刻画了神经网络特征提取器的几何特征。许多研究已经证明，多种不同场景下、不同网络在不同数据集上都观测到了定义3.1.1中所描述的四个特性，说明 NC 是神经网络的 TPT 阶段会出现的一个普遍现象。在这四个特征中，**(NC2)** 是最相关的，因为它揭示了标准和对抗特征塌缩之间最显著的区别，即广义单纯形 ETF 定义的单纯形压缩现象。因此，本文的剩余部分将主要关注 **(NC2)**。

定义 3.1.2 (**广义单纯形等角紧框架** [**?**]) 给定正整数 $d'>K$ 与矩阵

$$\boldsymbol{W}=(\boldsymbol{W}_1,\boldsymbol{W}_2,\cdots,\boldsymbol{W}_K)\in\mathbb{R}^{d'\times K}\tag{3.6}$$

如果 $\boldsymbol{W}=c_1\boldsymbol{U}\boldsymbol{M}$ 成立，则我们称 $\boldsymbol{W}$ 为一个广义单纯形等角紧框架。其中

$$\boldsymbol{M}=\sqrt{\frac{K}{K-1}}\left(\boldsymbol{I}_K-\frac{1}{K}\mathbf{1}_K\mathbf{1}_K^\top\right)\in\mathbb{R}^{K\times K},\tag{3.7}$$

$\boldsymbol{U}\in\mathbb{R}^{d'\times K}$ 是一个半正交矩阵（partial orthogonal matrix），即 $\boldsymbol{U}^\top\boldsymbol{U}=\boldsymbol{I}$，且 $c_1\in\mathbb{R}$ 是一个非零常数。 ▲

值得指出的是，在 NC 研究中，单纯形 ETF 的定义与数学文献中的定义略有不同 [17,18]。为了消除歧义，本文中所有关于单纯形 ETF 的讨论都基于定义3.1.2。

§3.2 实证研究

本章将通过实证研究，系统地探索标准和对抗特征塌缩之间的差异。我们首先研究对抗特征塌缩现象，然后探索对抗特征塌缩与标准特征塌缩之间的差异，揭示单纯形压缩现象。我们还提供了一系列消融实验，以消除扰动范数和 PGD 迭代步数的影响。

§3.2.1 实验设置

数据集：我们使用以下三个视觉数据集进行实验。`CIFAR-10` [?] 包含 60,000 张 32x32 像素的彩色图像，分为 10 类，每类 6,000 张。`CIFAR-100` 包含 60,000 张 32x32 像素的彩色图像，分为 100 类，每类 600 张。`Tiny ImageNet` [?] 包含 200 类，每类 500 张 64x64 像素的彩色图像。

模型：我们使用 VGG [?], ResNet [?], 和 Wide ResNet (WRN) [?] 进行实验。具体的选择网络深度和宽度取决于数据集。我们参考支持信息文件获取更多细节。

3.2.1.0.1 Models **对抗训练方法：**我们使用三种基于 PGD 的对抗训练方法，包括标准 `PGD-AT` [?], `TRADES` [?], 和 `MART` [?]。许多之前的工作 [?, ?, ?] 使用这些方法作为基准。许多之前的工作 [?, ?, ?] 使用这些方法作为基准。我们设置 PGD 的最大迭代步数为 $T_a = \{10, 20, 30\}$，扰动半径为 $\epsilon = \{2/255, 4/255, 6/255, 8/255\}$ 用于 L_∞ 范数，和 $\epsilon = \{0.125, 0.250, 0.375, 0.500\}$ 用于 L_2 范数。我们的 T_a 和 ϵ 的选择与许多之前的工作 [?, ?, ?, ?, ?] 和社区的标准化对抗鲁棒性基准[a] 一致。

3.2.1.0.2 Adversarial Training Methods. We conduct experiments using three PGD-based classical AT methods, including standard PGD-AT [?], TRADES [?], and MART [?]. Many previous works [?, ?, ?] use these methods as baselines. We set the maximum iteration steps for PGD to $T_a = \{10, 20, 30\}$ with perturbation radius of $\epsilon = \{2/255, 4/255, 6/255, 8/255\}$ for the L_∞ norm, and $\epsilon = \{0.125, 0.250, 0.375, 0.500\}$ for the L_2 norm. Our choices of T_a and ϵ are consistent with many previous works [?, ?, ?, ?, ?] and the standardized adversarial robustness benchmark[b] in the community.

3.2.1.0.3 Implementation Details. We implement experiments using PyTorch [?] on an Ubuntu 64-bit Linux workstation having a 10-core Intel Xeon Silver CPU (2.20

[a] https://robustbench.github.io/

[b] https://robustbench.github.io/

GHz) and eight Nvidia GeForce RTX 4090 GPUs. All networks are trained for 200 epochs to reach the terminal phase of training, at which point the phenomenon of NC occurs. We use stochastic gradient descent (SGD) with momentum = 0.9 and weight decay = 0.001. The batch size is 128, and the learning rate is 0.001. We keep other parameters consistent with the referenced articles [?, ?, ?, ?].

§3.2.2 Neural Collapse in Adversarial Training

In this subsection, we train Resnet-18 on the CIFAR-10 dataset using PGD-AT, MART, and TRADES. For each epoch, we calculate the numerical characteristics of NC1-NC4 using adversarial examples crafted from in the training data. As illustrated in Figure 3.2, our experiments substantiate the occurrence of NC phenomena (NC1-NC4) within our settings, thereby serving as a critical underpinning for our analyses. This observation is consistent with findings reported in prior studies [?, ?]. The remaining results can be found in the supporting information file (cf. Fig. S2 - S10).

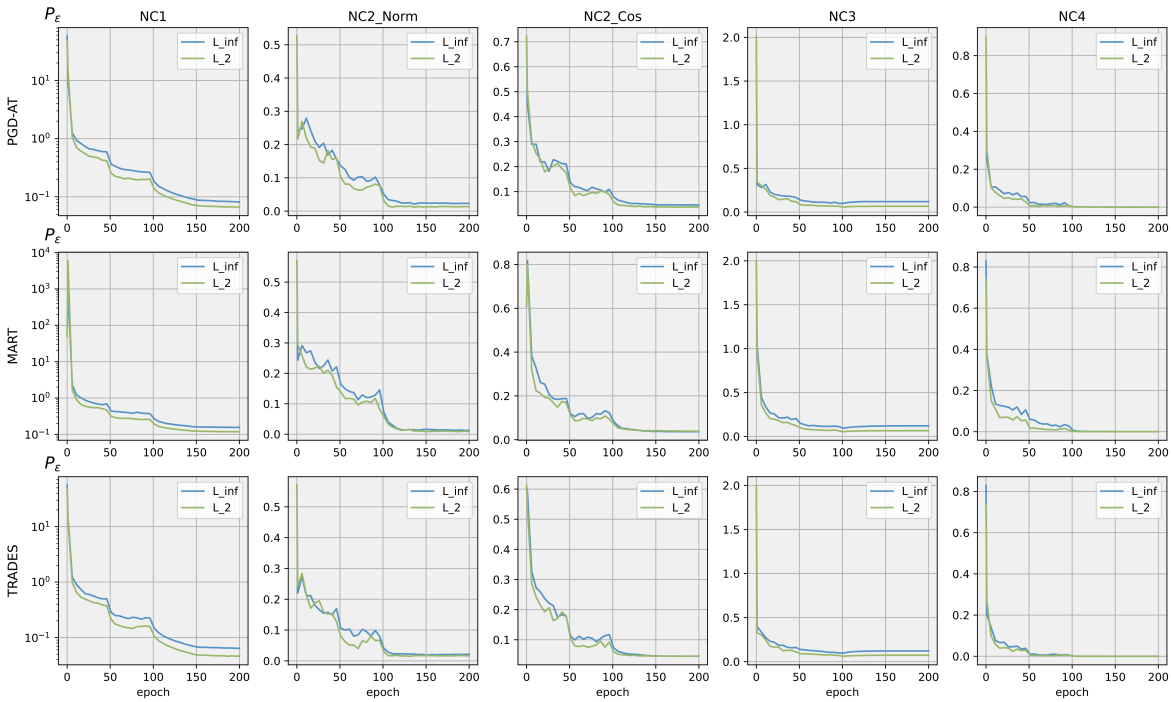

图 3.2: *Result of $NC1, NC2_Norm, NC2_Cos, NC3, NC4$. We train ResNet-18 on the CIFAR-10 dataset using PGD-AT, MART and TRADES, respectively. The perturbation radius are set to $\epsilon = 8/255$ for $L_\infty(L_\infty)$ and $\epsilon = 0.125$ for L_2. We set $T_a = 10$. The results are obtained from adversarial samples.*

§3.2.3 Simplex Compression Phenomenon

In this subsection, we investigate the influence of AT on the feature representations of the last layer. We define the average inter-class feature distance as the difference between the mean feature vector of each class and the global mean feature vector across all classes, expressed mathematically as:

$$\boldsymbol{P}_\epsilon = \frac{1}{K}\sum_{k=1}^{K}\left\|\bar{\boldsymbol{h}}_k - \bar{\boldsymbol{h}}_G\right\|_2 . \tag{3.8}$$

We set the same perturbation radius ϵ and PGD iterations for each experiment. The results of PGD-AT, TRADES and MART are shown in **??** (the results of L_2 norm are in SI Appendix Fig. S1.). We can see that $\boldsymbol{P}_\epsilon$ decreases as ϵ increases in each figure. This observation suggests the geometric size of the simplex ETF structure decreases as the perturbation radius increases. We refer to this experimental finding as the *simplex compression phenomenon*.

§3.2.4 Ablation Experiment

In the context of AT, the selection of hyper-parameters plays a pivotal role in defining the robustness and adaptability of learning models. Specifically, the choice of norms to quantify the deviation between adversarial and natural examples is critical. The L_∞ norm focuses on the maximum component of the perturbation vector, and the L_2 norm measures the Euclidean distance between clean examples and adversarial examples. Both are commonly used norms for characterizing adversarial perturbations. Furthermore, the iterative process of generating adversarial examples, as delineated in Equation (**??**), necessitates multiple iterations for convergence.

To investigate the potential confounding effects of these hyper-parameters in previous experiments, we design additional experiments with varying hyperparameter selections. For the L_∞ norm, perturbation radius are set to $\epsilon = \{0, 2/255, 4/255, 6/255, 8/255\}$, while for the L_2 norm, they are adjusted to $\epsilon = \{0, 0.125, 0.250, 0.375, 0.500\}$. These selections are consistent with those used in previous experiments. And we set PGD iterations $T_a = \{10, 20, 30\}$ to repeat our experiments. The results are displayed in 3.3. We can see that simplex compression exits for different perturbation norms and PGD iterations.

Furthermore, we extend our analysis by presenting the results of $\boldsymbol{P}_\epsilon$ for clean examples. As shown in 3.4, we observe that the $\boldsymbol{P}_\epsilon$ values for clean examples are

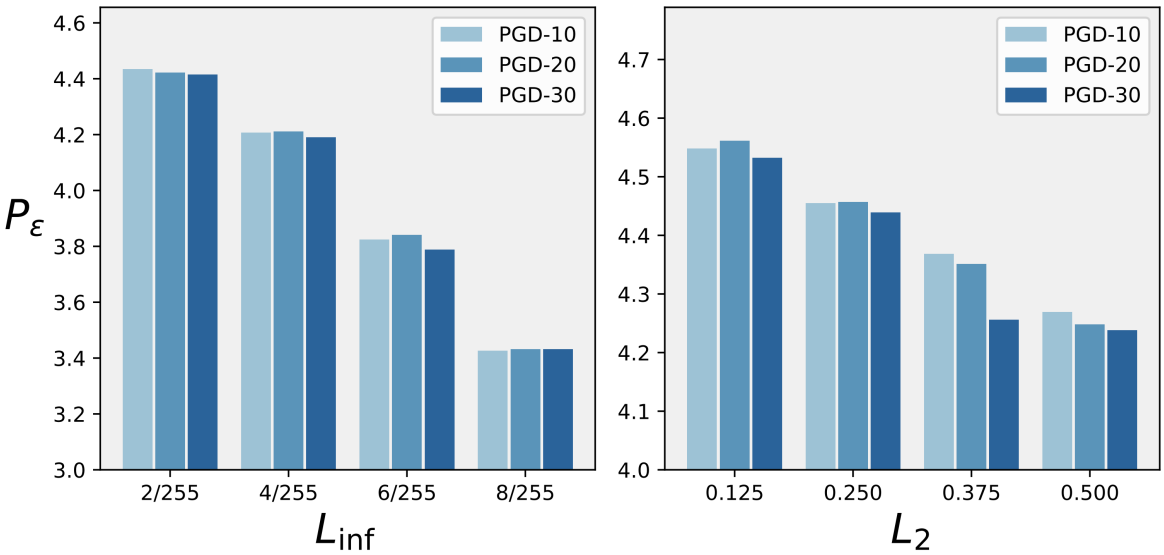

图 3.3: *Result of* $\boldsymbol{P}_\epsilon$. *We train ResNet-18 on the CIFAR-10 dataset using PGD-AT. We choose* $T_a = \{10, 20, 30\}$ *and norm* $p = \{L_\infty, L_2\}$. *The results are obtained from adversarial samples. Here, 'PGD-10' means* $T_a = 10$.

comparatively larger than those for adversarial examples, but they remain consistent with the simplex compression phenomenon.

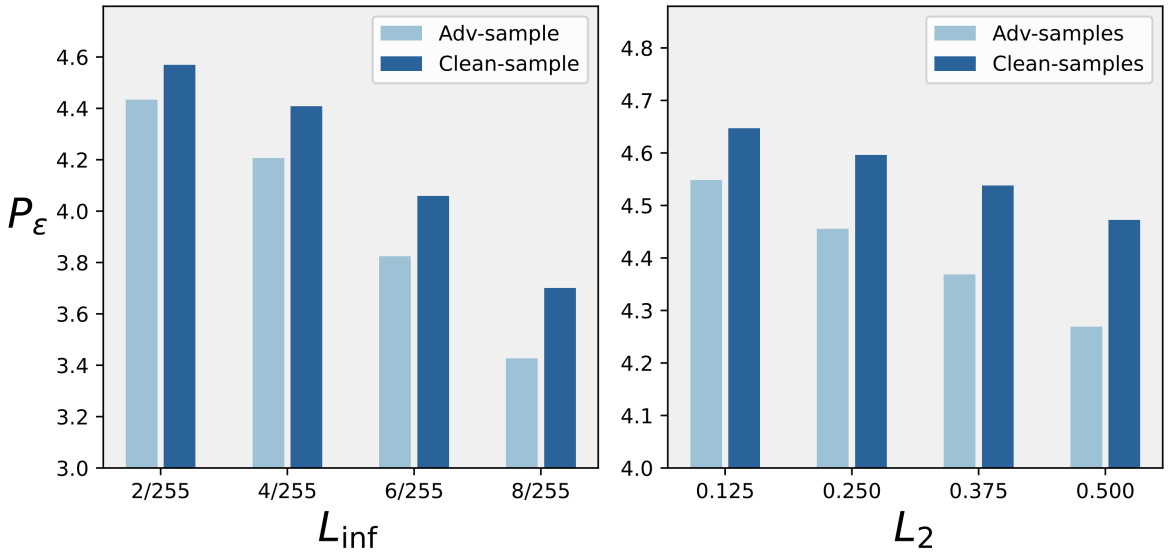

图 3.4: *Result of* $\boldsymbol{P}_\epsilon$*. We train ResNet-18 on the CIFAR-10 dataset using PGD-AT. We choose* $T_a = 10$ *and norm* $p = \{L_\infty, L_2\}$*. The results are obtained from adversarial samples and clean samples. The 'Adv-samples' means adversarial samples.*

第四章　图像任务的特征学习理论

第五章　文本任务的特征学习理论

第六章　总结与展望

参考文献

[1] CAO Y, CHEN Z X, BELKIN M, et al. Benign Overfitting in Two-layer Convolutional Neural Networks[C]//Proceedings of the 36th Annual Conference on Neural Information Processing Systems. Red Hook: Curran Associates, Inc., 2022.

[2] ALLEN-ZHU Z, LI Y Z. Feature Purification: How Adversarial Training Performs Robust Deep Learning[C]//Proceedings of the 62nd Annual Symposium on Foundations of Computer Science. Los Alamitos: IEEE Computer Society, 2021.

[3] CAO Y, CHEN Y B, LIU W W. Prevalence of Simplex Compression in Adversarial Deep Neural Networks[J]. Proceedings of the National Academy of Sciences of the United States of America, 2025.

[4] ALLEN-ZHU Z, LI Y Z. Towards Understanding Ensemble, Knowledge Distillation and Self-Distillation in Deep Learning[C]//Proceedings of the 11th International Conference on Learning Representations. OpenReview.net, 2023.

[5] WEN Z X, LI Y Z. Toward understanding the feature learning process of self-supervised contrastive learning[C]//Proceedings of the 34th International Conference on Machine Learning. PMLR, 2021: 11014-11024.

[6] HUANG W, CAO Y, WANG H N, et al. Graph Neural Networks Provably Benefit from Structural Information: A Feature Learning Perspective[C]//Proceedings of the 12th International Conference on Learning Representations. OpenReview.net, 2024.

[7] LU M, WU B N, YANG X D, et al. Benign Oscillation of Stochastic Gradient Descent with Large Learning Rates[C]//Proceedings of the 12th International Conference on Learning Representations. OpenReview.net, 2024.

[8] ZOU D F, CAO Y, LI Y Z, et al. The Benefits of Mixup for Feature Learning [C]//Proceedings of the 37th International Conference on Machine Learning. PMLR, 2023: 27265-27280.

[9] CHEN Y Q, HUANG W, ZHOU K W, et al. Towards Understanding Feature Learning in Out-of-Distribution Generalization[C]//Proceedings of the 37th International Conference on Machine Learning. PMLR, 2023: 4827-4837.

[10] CHEN Z X, DENG Y H, LI Y Z, et al. Understanding Transferable Representation Learning

and Zero-shot Transfer in CLIP[C]//Proceedings of the 12th International Conference on Learning Representations. OpenReview.net, 2024.

[11] CHEN Y B, LIU W W. Two-Layer Convolutional Autoencoders Trained on Normal Data Provably Detect Unseen Anomalies[C]//Proceedings of the 14th International Conference on Learning Representations. OpenReview.net, 2026.

[12] RUMELHART D, HINTON G E, WILLIAMS R J. Learning Internal Representations by Error Propagation[M]//Parallel Distributed Processing: Explorations in the Microstructure of Cognition, Vol. 1: Foundations. Cambridge: MIT Press, 1986: 318-362. ISBN 026268053X.

[13] BENGIO Y, COURVILLE A, VINCENT P. Representation Learning: A Review and New Perspectives[C]//Proceedings of the 2nd International Conference on Learning Representations. OpenReview.net, 2013.

[14] CHIZAT L, BACH F. Implicit Bias of Gradient Descent for Wide Two-layer Neural Networks Trained with the Logistic Loss[C]//Proceedings of the 33rd Conference on Learning Theory. PMLR, 2020: 1273-1316.

[15] PAPYAN V, HAN X, DONOHO D. Prevalence of neural collapse during the terminal phase of deep learning training[J]//Proceedings of the National Academy of Sciences of the United States of America. 2020.

[16] MADRY A, MAKELOV A, SCHMIDT L, TSIPRAS D, VLADU A. Towards Deep Learning Models Resistant to Adversarial Attacks[C]//International Conference on Learning Representations. 2017.

[17] STROHMER T, HEATH R. Grassmannian Frames with Applications to Coding and Communication[R]//CoRR. arXiv:math/0301135.

[18] FICKUS M, MIXON D G. Tables of the existence of equiangular tight frames[R]//CoRR. arXiv:1504.00253

[19] ZHANG H, YU Y, JIAO J, XING E, GHAOUI L, JORDAN M I. Theoretically Principled Trade-off between Robustness and Accuracy[C]//International Conference on Machine Learning. 2019.

攻博期间发表的科研成果目录

[1] 作者，文章题目，期刊名，年份（期数）：起止页码

[2] 作者，书名，版次，出版地：出版单位，年份，起止页码

致　　谢

感谢你，感谢他和她，感谢大家。